

Vorlesung Implementierung von Datenbanksystemen

11. Relationale Operatoren

Prof. Dr. Klaus Meyer-Wegener Wintersemester 2019/20

Grundsätzliche Aufgabe:

Ersetzen der Logischen Operatoren (SEL(), PROJ(), JOIN(), ...)
 durch (ausführbare) Planoperatoren

Teilprobleme

- Gruppierung von direkt benachbarten Operatoren zur Auswertung durch einen einzigen Planoperator
 - Beispiel: Verbund mit Selektionen und/oder Projektionen auf den beteiligten Relationen durch einen speziellen Planoperator gemeinsam ausführen.
- Bestimmung der Reihenfolge bei Verbundoperationen
 - Ziel: minimale Kosten für die Operationsfolge
 - Heuristik: Minimierung der Größe der Zwischenergebnisse,
 d.h. die kleinsten (Zwischen-)Relationen immer zuerst verknüpfen
- Erkennen gemeinsamer Teilbäume
 - Einmalige Berechnung
 - Dafür nötig: Zwischenspeicherung der Ergebnisrelation



Ausführbar

Unterprogramm / Komponente des DBMS

Parameter u.a.:

- Eingabe-Relationen
- Zu verwendende Indexstrukturen
- Bedingungen (Prädikate)

Voraussetzungen:

Vorhandensein bestimmter Speicherungsstrukturen (vor allem: Indexe)

Ergebnis (Ausgabe):

- Ganze Relation oder
- Nächstes Tupel (Pipelining) oder
- Nächste n Tupel

Kosten der Verarbeitung

Zeit, Speicher, CPU, ...



SQL erlaubt komplexe Anfragen über k Relationen.

Ein-Variablen-Ausdrücke

 beschreiben Bedingungen für die Auswahl von Elementen aus einer Relation.

Zwei-Variablen-Ausdrücke

 beschreiben Bedingungen für die Kombination von Elementen aus zwei Relationen.

k-Variablen-Ausdrücke

 werden typischerweise in Ein- und Zwei-Variablen-Ausdrücke zerlegt und durch entsprechende Planoperatoren ausgewertet.



Planoperatoren (3)

Selektion

- Mehrere Planoperatoren zur Auswahl
- Nutzung eines Scan-Operators
 - Wahlweise mit Definition von Start- und Stopp-Bedingung und von einfachen Suchargumenten (z.B. Attribut = Wert)
- Relationen-Scan
 - Sequenzielles Lesen aller Tupel einer Relation
- Index-Scan
 - Direkt auf erstes passendes Tupel springen, dann ggf. sequenziell die weiteren
 - Nach Auswahl des kostengünstigsten Index

Projektion

- Typischerweise mit im Planoperator von Sortierung, Selektion oder Verbund durchgeführt
 - Denn die bearbeiten sowieso jedes Tupel.
- Zusätzlich auch noch als eigener Planoperator



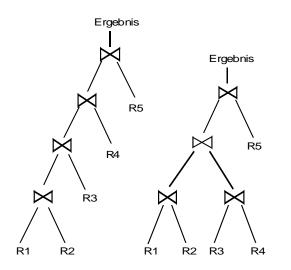
Planoperatoren (4)

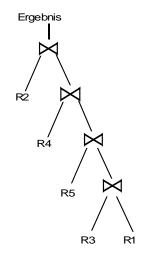
Sortierung

- Erforderlich bei ORDER BY
 - Aber auch zur Beschleunigung von Joins
 - Siehe unten
 - Und für Gruppierung
 - Und zur Duplikateliminierung (DISTINCT, Mengenoperationen)
- Deshalb eigener Planoperator
- Leider "blockierend":
 - Muss das letzte Eingabetupel abwarten, bevor die erste Ausgabe erzeugt werden kann
 - Kein Pipelining möglich
- I.Allg. extern, d.h. sortierte Teilergebnisse müssen auf Hintergrundspeicher ausgelagert werden (sog. Runs)
 - Am Schluss zum Gesamtergebnis zusammenmischen (Merge)



- Join über mehreren Relationen (n-Wege-Verbunde)
 - Zerlegung in n 1 Zwei-Wege-Verbunde
 - Anzahl der Verbundreihenfolgen abhängig von den Verbundattributen
 - n! verschiedene Reihenfolgen möglich
 - Optimale Auswertungsreihenfolge abhängig von
 - Planoperatoren,
 - "passenden" Sortierordnungen für Verbundattribute,
 - Größe der Operanden usw.
 - Verschiedene Verbundreihenfolgen mit Zwei-Wege-Verbunden (n = 5):







Eigenschaften der Verbundoperation:

- Teuer und häufig → Optimierungskandidat !!!
- Typisch: Gleichverbund; allgemeines Verbundprädikat eher selten
- Standardszenario:

Mögliche Zugriffspfade:

- Relationen-Scan über R und S
- Scans über Indexe I_R(VA) und I_S(VA), falls vorhanden
 - Dabei besonders interessant: Sortierreihenfolge nach R.VA und S.VA !!!
- Scans über Indexe I_R(SA) und/oder I_S(SA), falls vorhanden
 - Schnelle Selektion f
 ür R.SA und S.SA !!!
- Beliebige andere Kombinationen



Annahmen:

- Sätze in R und S sind nicht nach den Verbundattributen geordnet.
- Es sind keine Indexstrukturen I_R(VA) und I_S(VA) vorhanden.

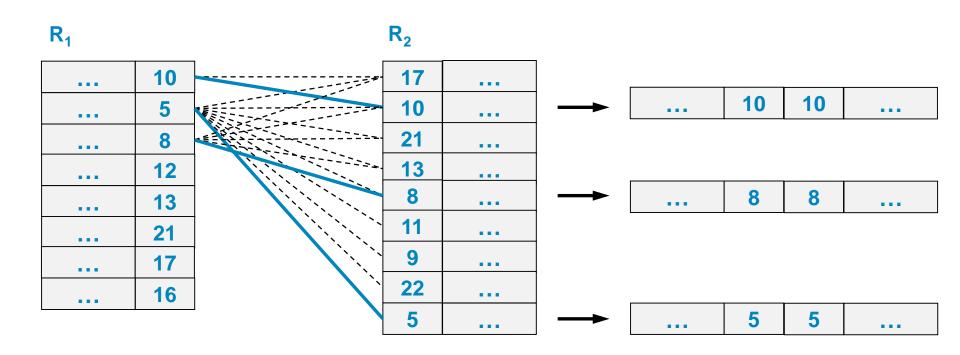
Algorithmus für Θ-Verbund:

```
Scan über S; // äußere Schleife für jeden Satz s, für den P(s.SA) gilt: Scan über R; // innere Schleife für jeden Satz r, für den P(r.SA) AND (r.VA \Theta s.VA) gilt: übernimm kombinierten Satz (r, s) in das Ergebnis;
```

Komplexität:

O(N²)





Merke:

 Falls das Verbundattribut der zweiten Relation die Eigenschaft UNIQUE aufweist, kann die Suche abgebrochen werden, nachdem der erste Verbundpartner gefunden wurde.



Annahme:

- Es sind Indexstrukturen I_R(VA) und I_S(VA) vorhanden.
- Algorithmus für Gleichverbund mit Indexzugriff:

```
Scan über S; für jeden Satz s, für den P(s.SA) gilt: ermittle über I_R(R.VA) alle (TIDs der) Sätze mit r.VA = s.VA; ggf. für jedes TID: hol Satz r; für jeden Satz r, für den P(r.SA) gilt: übernimm kombinierten Satz (r, s) in das Ergebnis;
```

Merke:

- Eigentlich wird seitenweise vorgegangen.
 - Mehrfachen Zugriff auf dieselbe Seite vermeiden

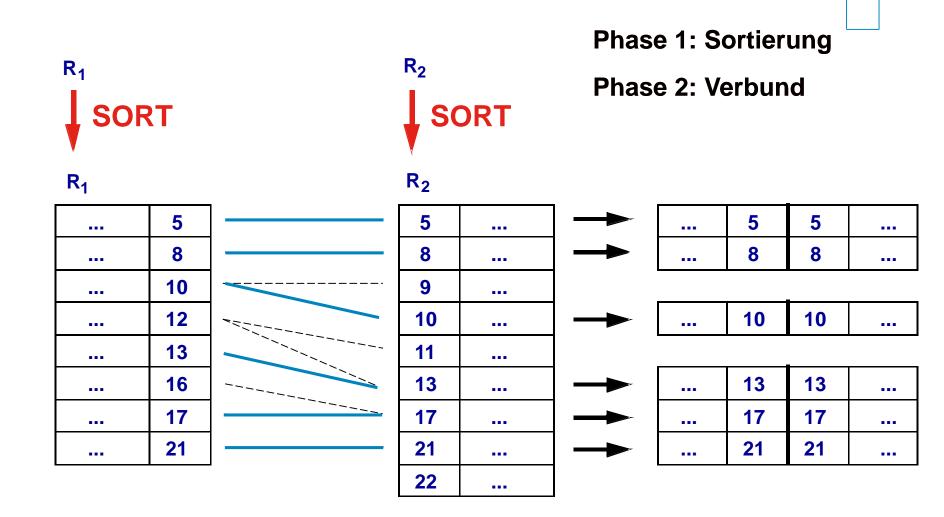


Zweiphasiger Algorithmus

- Phase 1:
 - Sortierung von R und S nach R.VA und S.VA (falls nicht bereits vorhanden), dabei frühzeitige Eliminierung nicht benötigter Tupel (durch Überprüfung von P(R.SA) bzw. P(S.SA))
- Phase 2:
 - Schritthaltende Scans über sortierte Relationen R und S mit Durchführung des Verbunds bei r.VA = s.VA (d.h. auch Gleichverbund)
- Komplexität: O(N log N)
- Ausnutzen von Indexstrukturen I_R(VA) und I_S(VA) mit Sortierordnung:

```
Schritthaltende Scans über I_R(R.VA) und I_S(S.VA); für jeweils zwei Schlüssel aus I_R(R.VA) und I_S(S.VA), für die r.VA = s.VA gilt: hol mit den zugehörigen TIDs die Tupel; für jedes Paar (r, s), für das P(r.SA) und P(s.SA) gelten: übernimm kombinierten Satz (r, s) in das Ergebnis;
```







Immer größere Hauptspeicher verfügbar

Ausnutzen für Zwischenergebnisse

Gleichverbund

Sehr häufiger Fall

Idee:

- Tupel der einen Relation so im Hauptspeicher ablegen, dass sie über Verbundattribut schnell gefunden werden können
- Tupel der anderen Relation sequenziell durchlaufen und mit Wert des Verbundattributs die passenden Verbundpartner im Hauptspeicher aufsuchen

Organisation der Tupel im Hauptspeicher?

Naheliegend: über Hashing



Einfachster Fall ("Classic Hashing")

- Äußere Schleife:
 - Abschnittweises Lesen der (kleineren) Relation R
 - Aufteilen in p Abschnitte R_i ($1 \le i \le p$) derart, dass
 - jeder der p Abschnitte in den verfügbaren Hauptspeicher passt;
 - jeder Satz, der gehasht wird, P(R.SA) erfüllt.
 - Aufbau einer Hash-Tabelle mit h_A(r.VA) nach Werten von R(VA)
- Innere Schleife (für jeden Abschnitt R_i):
 - Überprüfung ("Probing") für jeden Satz von S, der P(S.SA) erfüllt:
 - Ebenfalls Hashing h_A(s.VA)
 - Verbundpartner (falls vorhanden) muss sich an dieser Adresse befinden
 - Im Erfolgsfall Durchführung des Verbunds

Merke:

- Komplexität: O(p × N)
- Idealfall: R passt ganz in den Hauptspeicher, d.h. p = 1



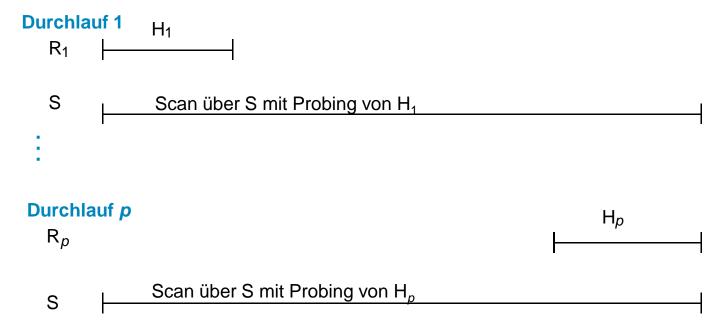
Pseudocode:

```
Berechne Anzahl p der Abschnitte der kleineren Relation R,
so dass jeder Abschnitt in den Hauptspeicher passt;
Scan über R:
für jeden Abschnitt R<sub>i</sub>, 1 <= i <= p:
   für jeden Satz r, der P(r.SA) erfüllt:
          Hash über r.VA, Ablage im Hauptspeicher;
   Scan über S:
   für jeden Satz s, der P(s.SA) erfüllt:
          Hash über s.VA, "Probing" im Hauptspeicher;
          bei Erfolg (Satz r mit r.VA = s.VA):
                 übernimm kombinierten Satz (r, s)
                 in das Ergebnis;
   Hauptspeicherinhalt (Hash-Tabelle) leeren;
```



Aufbau der Hash-Tabelle und Probing

- Hash-Tabellen H_i (1 $\leq i \leq p$) werden schrittweise im Hauptspeicher aufgebaut.
- Nach jedem Durchlauf von S wird die Hash-Tabelle wieder gelöscht.

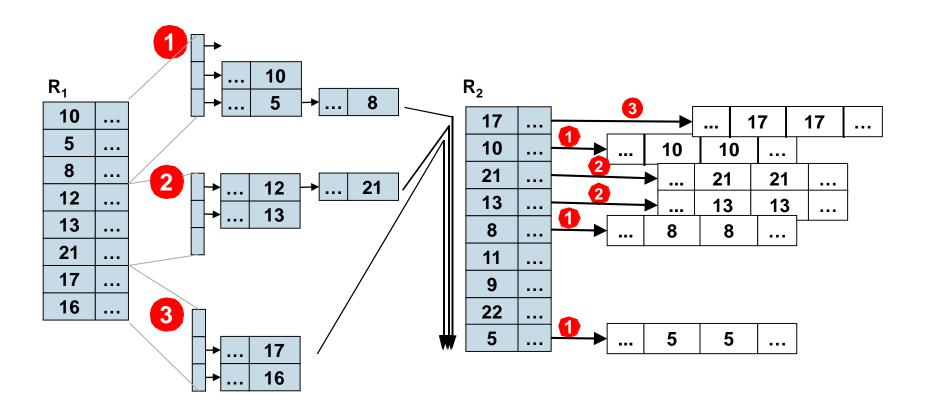




Beispiel zum Hash-Verbund

Annahme: Hauptspeicherkapazität = 3 Tupel

Hashing von R_1 mit $h(x) = x \mod 3$





Nachteil des Hashing:

Verbundpartner S muss p-mal gelesen werden.

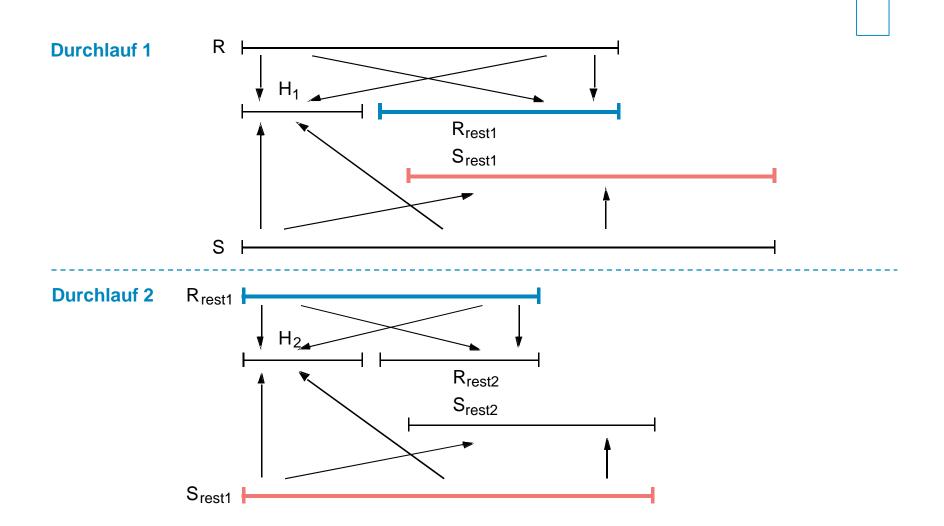
Idee:

- Warum nicht auch S (analog zu R) partitionieren?
- Hashing von R nicht nach der Reihenfolge der Tupel, sondern wertemäßig durchführen
 - → Partitionierung von R nach Werten von R.VA
- Aber:
 - Nicht einfach, da üblicherweise keine Gleichverteilung der Werte vorliegt
 - Heranziehen von Statistiken (insbes. Histogramme!)
- Zum Probing auch S nach den gleichen Kriterien partitionieren

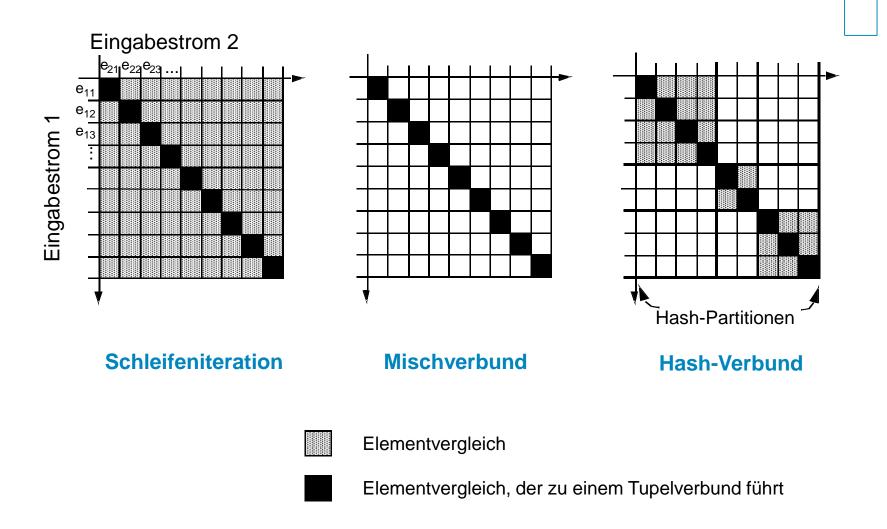
Vielzahl unterschiedlicher Hash-Verfahren

"Simple Hashing"











Duplikat-Eliminierung:

- Klassisch durch Sortierung und "Gruppierung" im anschließenden Scan
- Möglich aber auch Hashing:
 - Duplikate werden zwangsläufig auf gleiche Adresse abgebildet.

Gruppierung:

- Klassisch durch Sortierung und Scan mit Aggregation pro Gruppe
- Aber ebenfalls über Hashing möglich:
 - Abbildung auf Zähler, bisherige Summe, bisheriges Minimum oder Maximum
 - Für Durchschnitt Kombination von Zähler und Summe



Ziel:

- Von der Anfrage (WAS?) zur Auswertung (WIE?)
- Ermittlung des kostengünstigsten Auswertungswegs

Zentrales Problem:

- Globale Optimierung ist im allgemeinen zu aufwändig.
 - Fehlen von exakten statistischen Informationen
 - Sehr großer Suchraum
- Deshalb Einsatz von Heuristiken
- Optimierungsziel
 - Entweder Maximierung des Outputs bei gegebenen Ressourcen
 - Durchsatzmaximierung (in Transaktionen pro Sekunde)
 - Oder Minimierung der Ressourcennutzung für gegebenen Output
 - Antwortzeitminimierung für eine gegebene Anfragesprache, einen Mix von Anfragen verschiedenen Typs und eine gegebene Systemumgebung



Berücksichtigung unterschiedlicher Kostenarten

- Berechnungskosten
 - CPU-Kosten
 - Pfadlängen (Anzahl Maschineninstruktionen)
- E/A-Kosten
 - Anzahl der physischen Referenzen
- Speicherungskosten
 - Temporäre Speicherbelegung im DB-Puffer und auf Externspeichern
- Kommunikationskosten (bei verteilten DBS)
 - Anzahl der Nachrichten
 - Menge der zu übertragenden Daten

Merke:

- Kostenarten sind nicht unabhängig voneinander.
- In DBVS oft gewichtete Funktion von Berechnungs- und E/A-Kosten



Erstellung und Auswahl von Ausführungsplänen

Eingabe:

- Algebraisch optimierter Anfragebaum
- Existierende Speicherungsstrukturen und Zugriffspfade
- Kostenmodell

Ausgabe:

Optimaler (eher: guter) Ausführungsplan

Zwei oft notwendige Annahmen:

- Alle Datenelemente und alle Attributwerte sind gleichverteilt.
- Suchprädikate in Anfragen sind unabhängig.

Beide Annahmen sind (im Allgemeinen) falsch!

- Beispiel:
 - (Gehalt ≥ 100.000) AND (Alter BETWEEN 20 AND 30) mit Gehalt: [10K .. 1M] und Alter: [20 .. 65]
 - Lineare Interpolation und Multiplikation von Wahrscheinlichkeiten eher nicht angemessen ...



11 - 26

Erstellung und Auswahl von Ausführungsplänen (2)

Vorgehensweise (vereinfacht):

- Generieren aller "vernünftigen" logischen Ausführungspläne zur Auswertung der vorliegenden Anfrage
- Vervollständigen der Ausführungspläne mit Einzelheiten aus der physischen Datenrepräsentation (Sortierreihenfolge, Zugriffspfadmerkmale, statistische Information)
- Bewertung der generierten Alternativen und Auswahl des billigsten Ausführungsplans gemäß dem vorgegebenen Kostenmodell

Merke:

- Wie entstehen alternative Ausführungspläne ???
 - Planoperatoren liegen in verschiedenen Implementierungen vor.
 - Operationsreihenfolgen (z.B. bei Mehrfachverbunden) können variiert werden.
- Entstehung sehr großer Suchräume bei komplexen Anfragen mit allen Alternativen
 - Beispiel: ca. 10²³ mögliche Ausführungspläne bei einer Anfrage mit 15 Verbunden
 - 15! (Reihenfolge) * 3¹⁵ (versch. Planoperatoren) * 2¹⁵ (Index- o. Table-Scan)



Ziel der Plangenerierung

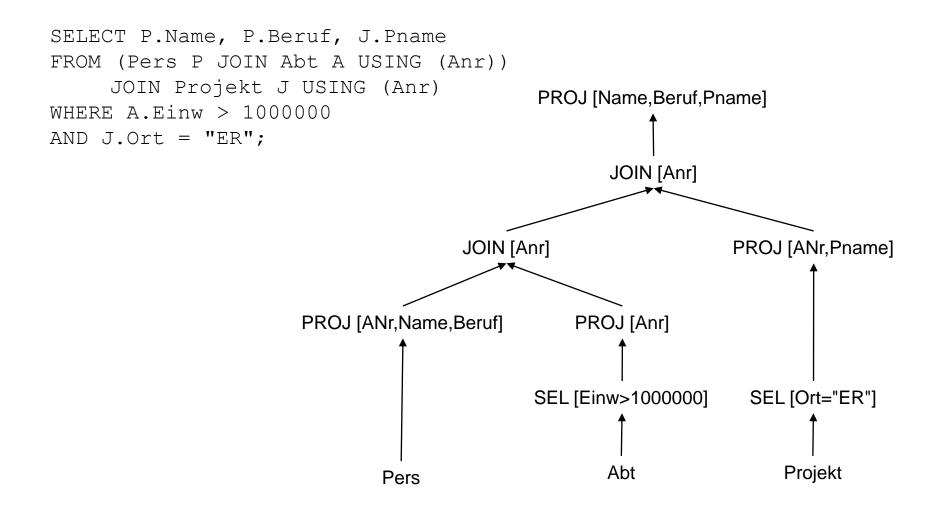
- Auffinden eines guten Plans
 - Gelingt immer und geht schnell
- Mit einer möglichst kleinen Anzahl generierter Pläne auskommen

Unterschiedliche Strategieklassen:

- voll-enumerativ
- beschränkt-enumerativ
- zufallsgesteuert
 - genetische Algorithmen und die Strategien des "simulated annealing"



Beispiel zur Auswahl eines Ausführungsplans





Beispiel (2)

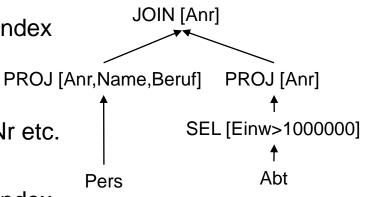
Mögliche Zugriffspfade für die einzelnen Relationen

- Relation Pers:
 - Index I_P(ANr) nicht eindeutig, für den Join mit Abt und Proj
 - Scan(P)
- Relation Abt:
 - Index I_A(ANr) eindeutig, für den Join mit Pers und Proj
 - Index I_A(Einw) für die Selektion
 - Scan(A)
- Relation Proj:
 - Index I_J(ANr) nicht eindeutig, für den Join mit Pers und Abt
 - Index I_J(Ort) für die Selektion
 - Scan(J)



Nested-Loop-Join von Pers und Abt

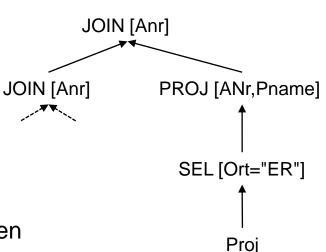
- Mit Abt anfangen
 - I_A(Einw) benutzen für Selektion
 - Bei jedem Treffer gleich Projektion auf ANr
 - I_P(ANr) benutzen für Join-Partner
 - Direktzugriff über ANr, kann jeder Index
 - Evtl. mehrere Join-Partner
- Mit Pers anfangen
 - Scan(P) benutzen mit Projektion auf ANr etc.
 - I_A(ANr) benutzen für Join-Partner
 - Direktzugriff über ANr, kann jeder Index
 - Immer nur ein Join-Partner





- Zwischenergebnisse haben keinen Index.
 - Nur Scan möglich
- Nested-Loop-Join von (Pers, Abt) mit Proj
 - Scan(P,A) benutzen
 - I_J(ANr) benutzen für Join-Partner
 - Direktzugriff über ANr, kann jeder Index
 - Mehrere Join-Partner
 - Selektionsbedingung pr

 üfen
 - Alternativ I_J(Ort) benutzen hohe Selektivität?
 - Dann das (kleine) Ergebnis für jedes Tupel von Scan(P,A) sequenziell nach Join-Partnern durchsuchen





Weitere Möglichkeiten:

- Falls I_A(ANr) und I_P(ANr) Sortierung nach Schlüssel bieten: Sort-Merge-Join
- Erst Join (A,J), dann Join des Ergebnisses mit P
 - Also andere Join-Reihenfolge
- ...



Kostenvoranschlag

für jeden Ausführungsplan (möglicher Lösungsweg)

Kostenformel

- Gewichtetes Maß für E/A- und CPU-Belastung:
 Kosten: #physische-Seitenzugriffe + W × #Aufrufe-des-Zugriffssystems
 - W ist das Verhältnis des Aufwands für einen Aufruf des Zugriffssystems (interne Satzschnittstelle) zum Aufwand für einen Seitenzugriff
- Ziel der Gewichtung: Minimierung der Kosten abhängig vom Systemtyp
 - CPU-bound: höherer E/A-, geringerer CPU-Aufwand
 - Beispiel für W:

```
W<sub>CPU</sub> = #Instr-pro-Aufruf-des-Zugriffssystems / #Instr-pro-E/A-Vorgang
```

- I/O-bound: geringerer E/A-, höherer CPU-Aufwand
 - Beispiel für W:

```
W<sub>IO</sub> = #Instr-pro-Aufruf-des-Zugriffssystems / 
(#Instr-pro-E/A-Vorgang + Zugriffszeit × MIPS-Rate)
```



Statistische Größen für Segmente

- M_S Anzahl der Datenseiten des Segments S
- L_s Anzahl der leeren Seiten in S

Statistische Größen für Relationen

- N_R Anzahl der Tupel in Relation R (auch card(R) oder | R |)
- T_{R.S} Anzahl der Seiten in S mit Tupeln von R
- C_R Cluster-Faktor (Anzahl der Tupel von R pro Seite)

Statistische Größen pro Index I auf Attributen A einer Relation R

- j_I Anzahl der Attributwerte (Schlüsselwerte) im Index (= card(PROJ(R,A))
- B_I Anzahl der Blattseiten (beim B*-Baum)

Merke:

Statistiken müssen gesammelt und im DB-Katalog gewartet werden.



Ermittlung statistischer Kenngrößen (2)

- Problem: Aktualisierung bei jeder Änderung sehr aufwändig
 - Zusätzliche Schreib- und Log-Operationen
 - DB-Katalog wird zum Sperr-Engpass
- Alternative:
 - Initialisierung der statistischen Werte zum Lade- oder Generierungszeitpunkt von Relationen und Indexstrukturen
 - Periodische Neubestimmung der Statistiken durch eigenes Kommando oder Dienstprogramm
 - DB2: runstats on table ...
 - Oracle: analyse table ...



Ermittlung eines Selektivitätsfaktors SF (0 ≤ SF ≤ 1)

- Erwarteter Anteil an Tupeln, die ein Prädikat p erfüllen:
 SF(p) = card(SEL(R,p)) / card(R)
- Beispiel-Heuristiken zur Abschätzung des Selektivitätsfaktors:

Prädikat	SF	wenn
$A_i = a_i$	1 / j _{li} 1 / 10	Index I _i auf Attribut A _i sonst
$A_i = A_k$	1 / MAX(j _{li} , j _{lk}) 1 / j _{li} 1 / j _{lk} 1 / 10	Index auf beiden Attributen Index nur auf A _i Index nur auf A _k sonst
$A_i > a_i$	$(a_{max} - a_i) / (a_{max} - a_{min})$ 1 / 3	Index auf A _i und Werte interpolierbar sonst



Beispiel-Heuristiken zur Abschätzung des Selektivitätsfaktors (Forts.):

Prädikat	SF	wenn
A _i BETWEEN a _i AND a _j	$(a_j - a_i) / (a_{max} - a_{min})$	Index auf A _i und Werte interpolierbar
	1 / 4	sonst
A _i IN	r/j _{li}	Index auf A _i und SF < 0,5
$(a_1, a_2,, a_r)$	1/2	sonst

Berechnung von Verbundtermen im Qualifikationsterm

- $SF(p(A) \text{ and } p(B)) = SF(p(A)) \cdot SF(p(B))$
- $SF(p(A) \text{ or } p(B)) = SF(p(A)) + SF(p(B)) SF(p(A)) \cdot SF(p(B))$
- SF(not p(A)) = 1 SF(p(A))

Beachte:

Wieder die Annahme der Unabhängigkeit von Prädikaten!



Beispiel zur Selektivitätsabschätzung

Anfrage

```
SELECT Name, Gehalt FROM Pers
WHERE Beruf = "Programmierer" AND Gehalt >= 100000;
```

Vorhandene Zugriffspfade

- Relationen-Scan im Segment von Pers
- I_{Pers}(Beruf)
- I_{Pers}(Gehalt)

Vorhandene statistische Kennwerte

- N = Anzahl der Tupel in Relation Pers (N = 5000)
- C_{Pers} = durchschn. Anzahl von Pers-Tupeln pro Seite
- j_i = Index-Kardinalität (Anzahl der Attributwerte für A_i)
 - Es gibt 25 unterschiedliche Berufe.
 - Die Gehälter liegen zwischen 30.000 und 120.000.



- SF_B = SF(Beruf = "Programmierer") = 1 / j_{Beruf} = 1 / 25
- $SF_G = SF(Gehalt >= 100.000) = (120.000 100.000) / (120.000 30.000) = 0.22$
- Methode 1: Scan über I_{Pers}(Beruf)
 - Kosten: #physischer-Seitenzugriffe + W × #Aufrufe-des-Zugriffssystems
 (N × SF_B) + W × (N × (SF_B × SF_G)) = N / 25 + W × N × 0,0088
 - Index-Scan mit zusätzlichem einfachen Suchargument (Folie 11-5)
 - Beachte: Falls I_{Pers}(Beruf) Primärorganisation, reduziert sich die Anzahl der Seitenzugriffe um den Faktor C_{Pers} auf (N / C_{Pers}) × SF_B
- Methode 2: Scan über I_{Pers}(Gehalt)
 - Kosten: $(N \times SF_G) + W \times (N \times (SF_B \times SF_G)) = N \times 0.22 + W \times N \times 0.0088$
 - Beachte: Falls I_{Pers} (Gehalt) Primärorganisation, reduziert sich die Anzahl der phys. Seitenzugriffe um den Faktor C_{Pers} auf $(N / C_{Pers}) \times SF_G$

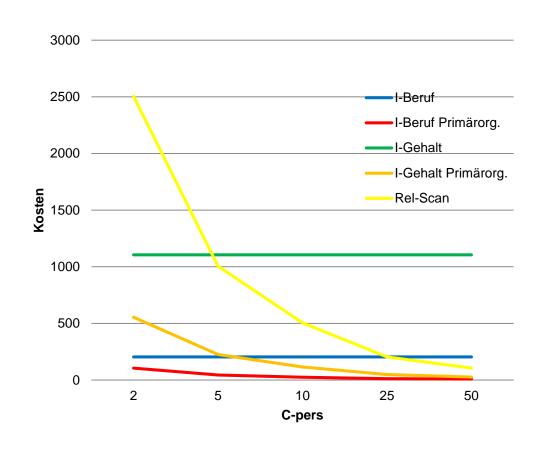


Beispiel zur Selektivitätsabschätzung (3)

Methode 3: Relationen-Scan

• Kosten: $(N / C_{Pers}) + W \times (N \times (SF_B \times SF_G)) = (N / C_{Pers}) + W \times N \times 0,0088$

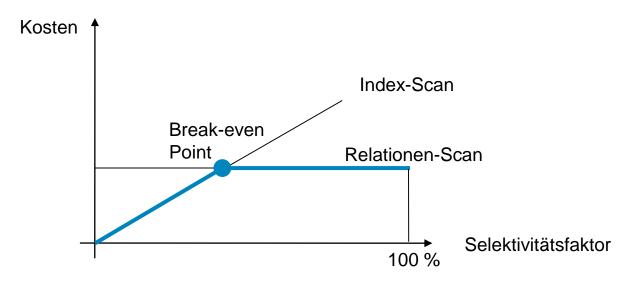
Kostenvergleich:





Folgerung:

- Vorhandene Indexstrukturen k\u00f6nnen die Laufzeit dramatisch reduzieren!
- Aber nur bei sehr geringen Trefferraten (= hoher Selektivität) lohnt sich ein Index-Scan.
- Qualitatives Zugriffsdiagramm:

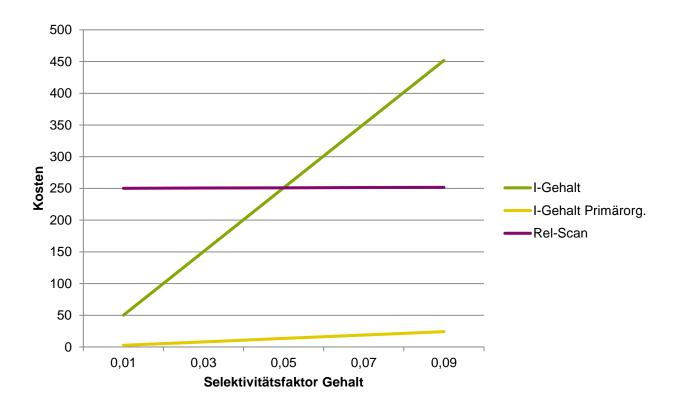


Grenztrefferrate liegt üblicherweise bei max. 5 %.



Am Beispiel:

- C_{pers} nun fest bei 20
- SF_G variiert





Ziel der Anfrageoptimierung

Ermittlung des kostengünstigsten Auswertungswegs

Standardisierung und Vereinfachung

Umformungs-, Idempotenzregeln, ...

Restrukturierung und Transformation

- Zuordnung von physischen Operatoren zu logischen
- Reihenfolge der Operatorenausführung

Erstellung und Auswahl von Ausführungsplänen

- Sehr große Suchräume bei komplexen Anfragen
- Strategieklassen: voll-enumerativ, beschränkt-enumerativ, zufallsgesteuert
- Berechnung der Zugriffskosten:
 - Abschätzung von Selektivitäten
 - Nutzung vorhandener Zugriffspfade und statistischer Kennwerte

