Zusammenfassung IDB

Marco Ammon

15. Februar 2019

1 Einführung

- Datenabstraktion / Datenunabhängigkeit: persistentes Speichern und Wiedergewinnen (Auffinden und Aushändigen) von Daten unabhängig von Details der Speicherung
- Schicht: realisiert Dienst und stellt ihn per Schnittstelle zur Verfügung

2 Dateiverwaltung

- physische Speichergeräte (z.B. Festplatten) werden durch logische abstrahiert (z.B. Neueinlesen bei Checksum-Fehlern)
- Block als kleinste Einheit der IO
- "Adresse" eines Blocks: (Zylinder, Spur, Sektor)
- Dateien als benannte Menge von Blöcken
- blockorientierte Zugriffsmethode: verwendet eindeutige, fortlaufende Blockadressen innerhalb der Datei

3 Sätze

- Satz als zusammengehörende Daten eines Gegenstands der Anwendung (z.B. Tupel, Objekt) mit variabler oder fester Länge
- Satzdatei als Sammlung von Sätzen, kann über verschiedene Blöcke verteilt sein
- Ausprägungen:
 - sequentiell:
 - * Reihenfolge der Abspeicherung und des Auslesens bereits mit Schreiben festgelegt
 - * keine Änderungen / Löschen möglich
 - * kein wahlfreier Zugriff
 - direkt:
 - * Verwendung sogenannter Satzadressen (hier als TIDs realisiert; eindeutig und unveränderlich) als Adresstupel (Block, Index)
 - * Abbildung von Index auf Offset innerhalb eines Blockes durch Array am Ende eines Blockes
 - * erlaubt wahlfreien Zugriff
 - * erlaubt Löschen von Sätzen: Index wird ungültig markiert, folgende Sätze nach vorne verschoben, Anpassung der Offsets
 - * erlaubt Ändern von Sätzen:

- · ohne Überlauf: Verschieben der folgenden Sätze, Anpassung der Offsets
- · mit Überlauf: Satz wird in anderen Block verschoben, Verweis auf diesen wird angelegt, (evtl.) Anpassung der Offsets

4 Schlüssel

- Schlüsselwerte als "inhaltsbezogene Adressen"
- Hashina:
 - Hash-Funktion verteilt Schlüsselwert möglichst gleichmäßig auf verfügbare Buckets (Blöcke)
 - Divisions-Rest-Verfahren: $h(k) = (k \mod q)$ mit Schlüsselwert k und Anzahl der Buckets q
 - Problem des Überlaufs mit verschiedenen Lösungsmöglichkeiten:
 - * Open Addressing: Ausweichen auf Nachbarbuckets
 - * spezielle Overflow-Buckets: Bucket verweist auf "seinen" Overflow-Bucket
 - virtuelles Hashing zur konstanten Reorganisation:
 - * Anzahl der Buckets q, Sätze pro Bucket $b \Rightarrow$ Kapazität $\coloneqq q \cdot b$
 - * Belegungsfaktor $\beta \coloneqq \frac{\text{Anzahl gespeicherter Sätze } N}{\text{Kapazität}}$
 - * Wenn $\beta >$ Schwellwert α , Menge der Buckets vergrößern
 - * als *VH1*:
 - · Anzahl der Blöcke direkt verdoppeln
 - · neue Hashfunktion h_2 einführen
 - · Bitmaske um Verwendung der neuen Hashfunktion zu verwalten
 - · bei Einfügen eines Satzes in ein "altes" Bucket Neuverteilung dieses Buckets mittels h_2 , Bit setzen
 - * als Lineares Hashing:
 - · Positionszeiger p
 - · ein neues Bucket anlegen
 - · Bucket an Stelle p mit h_2 aufteilen, p++
 - · wenn $h_1(k) < p$, dann mittels h_2 verteilen
- Indizes mittels Bäumen:
 - *− B-Baum*:
 - * jeder *Knoten* ist genau einen Block groß
 - st balanciert, alle Blätter außer Wurzel immer mindestens zur Hälfte gefüllt
 - * Knoten:
 - · Anzahl der verwendeten Einträge n, es gilt $k \le n \le 2k$
 - · Eintrag: Tupel (Schlüsselwert, Datensatz, Blocknummer des Kindknotens)
 - \cdot Einträge nach Schlüsselwert sortiert
 - * Einfügen: wie Suchen; nur in Blattknoten; bei Überlauf "linke" und "rechte" Einträge als neue Knoten, "mittlerer" als *Diskriminator* in Eltern-Knoten einfügen
 - * Löschen von Schlüssel S im Blattknoten:
 - · Entfernen und ggf. Unterlauf behandeln
 - * Löschen von Schlüssel S in innerem Knoten:
 - · betrachte die Blattknoten mit direktem Vorgänger S' und direktem Nachfolger S'' von S

- · wähle den größeren
- · ersetze S je nach Wahl durch S' bzw. S''
- · lösche entsprechenden Schlüssel S^\prime bzw. $S^{\prime\prime}$ und ggf. Unterlauf behandeln
- * Höhe:
 - · obere Schranke: $h(n) = \log_{k+1} \left(\frac{n+1}{2} \right) + 1$
 - · untere Schranke: $h(n) = \log_{2k+1} (n+1)$
- $-B^*$ -Baum / B+-Baum:
 - * Sätze stehen ausschließlich in Blattknoten
 - * innerer Knoten:
 - \cdot Anzahl der verwendeten Einträge n
 - · Eintrag: Tupel (Referenzschlüssel, Blocknummer des Kindknotens)
 - * Blattknoten:
 - Anzahl der verwendeten Einträge n
 - · Vorgänger-Zeiger, Nachfolger-Zeiger
 - · Eintrag: Tupel (Schlüsselwert, Datensatz)
 - * Löschen ohne Unterlauf: lösche Satz aus Blatt; Diskriminator muss nicht geändert werden
 - * Löschen mit Unterlauf:
 - · Ist Anzahl der Einträge des Blatts und eines Nachbarknotens größer als 2k, verteile Sätze neu auf beide Knoten
 - · ansonsten mische beide Blätter zu einem einzigen
- *− R-Baum*:
 - * ähnlich zu B-Baum
 - * multidimensional
 - * arbeitet mit Rechtecken
 - * beim Einfügen Rechteck nur möglichst gering vergrößern
- Müssen nicht zwangsläufig zur *Primärorganisation* verwendet werden, können als "Sätze" z.B. auch nur Satzadressen enthalten
- Bitmap-Indizes: eine Bitmap pro Schlüsselwert

5 Puffer

- Hauptspeicherbereich, der Blöcke aufnehmen kann, um (Lese-/Schreibe-) Zugriffe zu beschleunigen
- Ersetzungsstrategie: "Welcher Block wird verdrängt?"
 - first in, first out (FIFO): "ältester" Block
 - least frequently used (LFU): am seltensten benutzter Block
 - least recently used (LRU): am längsten nicht mehr benutzter Block
 - * Stacktiefenverteilung: "Wie tief liegen die referenzierten Seiten?"
 - second chance (CLOCK): Approximation von LRU mit einfacherer Implementierung:
 - * Jeder Block im Puffer besitzt ein Benutzt-Bit
 - * bei Verdrängung Suche mit Zeiger
 - * falls Benutzt-Bit 1, auf 0 setzen und Zeiger weiterschieben

- * falls Benutzt-Bit 0, Block ersetzen
- Working Set Size |W(t, w)|: Anzahl der unterschiedlichen referenzierten Seiten in den letzten w Zugriffen bis Zeitpunkt t
- aktuelle Lokalität: $AL(t, w) = \frac{|W(t, w)|}{w}$
- durchschnittliche Lokalität: $L(w) = \frac{\sum_{t=w}^{n} AL(t,w)}{n-w+1}$
- Zustand im Fehlerfall hängt unter anderem von Einbringstrategie (siehe Recovery) und Seitenzuordnung ab
- Seitenzuordnung: "Welche Blöcke (in einer Datei) gehören zu einer Seite (im Puffer)?"
 - direkt: aufeinander folgende Seiten werden auf aufeinander folgende Blöcke einer Datei abgebildet
 - indirekt: Page Table enthält zu jeder Seite eine Blocknummer
- Seiteneinbringung:
 - direkt: Bei Verdrängung aus Puffer wird genau der Block überschrieben, aus dem ursprünglich eingelagert wurde ("update-in-place")
 - indirekt: Bei Verdrängung aus Puffer wird in einen freien Block geschrieben.
- Problem der indirekten Seiteneinbringung: "Wann können alte Blöcke gelöscht werden?"; verschiedene Lösungsansätze:
 - Schattenspeicher:
 - * Änderungen nur auf Kopien, die periodisch dann mit "gesicherter" Version vertauscht wird
 - Twin Slots:
 - * jede Seite hat zwei Blöcke
 - * immer beide lesen, bei Änderungen älteren überschreiben

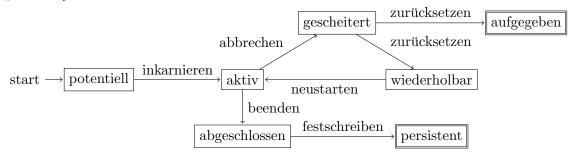
6 Programmzugriff

- Precompiler übersetzt SQL-Anweisungen (mittels EXEC SQL gekennzeichnet) zur Compile-Zeit in die verwendete Programmiersprache
 - Deklaration der verwendeten Variablen am Anfang mittels DECLARE SECTION
 - Fehlermeldungen und ähnliches werden über die sogenannte SQL communication area verwaltet (INCLUDE SQLCA am Anfang)
 - Mengen-orientes Paradigma des DBVS oft nicht mit Programmiersprache vereinbar \Rightarrow Einrichtung eines *Cursors* zum tupelweisen Durchlaufen der Ergebnismenge
 - Beispielablauf: DECLARE CURSOR \rightarrow OPEN \rightarrow (mehrfach) FETCH bis Fehlercode == $100 \rightarrow$ CLOSE
 - kann durch Präprozessor direkt als stored procedure angelegt werden
- Unterprogrammaufruf (Call-Level-Interface):
 - Übergabe der SQL-Anweisungen zur Laufzeit
 - Beispiel JDBC
 - * Connection con = DriverManager.getConnection(URL, USER, PASSWORD);
 - * Statement anweisung = con.createStatement();
 ResultSet ergebnis = anweisung.execureQuery(ANFRAGE);
 außerdem: int executeUpdate(String sql), boolean execute(String sql)
 - * while (ergebnis.next()) int pnr = ergebnis.getInt(1);

- Bei mehrfacher Ausführung der gleichen Abfrage mit unterschiedlichen Werten prepared statements sinnvoll:
 - * Anfrage enthält Platzhalter für Werte
 - * Analyse, Ausführungsplanerstellung und weiteres wird sofort durchgeführte
 - * JDBC:
 - PreparedStatement prep =
 con.prepareStatement("INSERT INTO ... VALUES (?,?)")
 - · Setzen der Werte mittels void setDATENTYP(int paramId, DATENTYP val)
 - · Ausführung mit prep.executeUpdate()
- bei stored-procedures nur noch einmaliges Analysieren, etc. zur Compile-Zeit erforderlich:
 - * Prozedur in DBVS bekommt "Namen", über den sie mit Werten als Parametern aufrufbar ist
 - * JDBC:
 - · CallableStatement call = con.prepareCall("{ call PROZEDUR }");
 - · Eingabe-Parameter analog zu prepared statements
 - · Ausgabe-Parameter mittels registerOutParameter(int paramId, int type)
- O/R-Mapping bildet Objekte der Programmiersprace (meist durch Annotationen) auf Tupel der relationalen DB ab

7 Transaktionen

- sinnvoll für nebenläufigen Zugriff
- erleichtern Umgang mit Fehlern und Ausfällen (siehe Recovery
- Transaktion als logische Einheit einer Folge von DB-Operationen (von einem logisch konsistenten Zustand zum nächsten):
 - bei Fehler vor Ende: Rückgängigmachen der bisher durchgeführten Änderungen
 - bei Fehler nach Ende: kein Problem
 - Anfang meist implizit (oder begin)
 - Ende durch commit (Änderungen sollen durchgeführt werden) bzw. abort/rollback (Änderungen sollen verworfen werden)
- ACID-Eigenschaften einer Transaktion:
 - Atomarität ("alles oder nichts" wird ausgeführt)
 - Konsistenz
 - Isolation (gegenüber anderen Zugriffen auf DB)
 - Dauerhaftigkeit (auch nach Fehler bleiben erfolgreiche Transaktionen bestehen)
- "Lebenszyklus" einer Transaktion



- Anomalien im Mehrbenutzerbetrieb:
 - dirty read: Lesen von nicht freigegeben Änderungen: $w_1[x], r_2[x]$, erst danach Commit / Rollback
 - dirty write: Überschreiben von nicht freigegebenen Änderungen: $w_1[x], w_2[x]$, erst danach Commit / Rollback
 - non-repeatable read: Änderung nachdem gelesen wurde: $r_1[x], w_2[x]$, erst danach Commit / Roll-back
 - Phantom-Problem: Ändern/Anlegen eines Tupels, das gelesenes Prädikat P erfüllt: $r_1[P], w_1[y \in P]$, erst danach Commit/Rollback
- Serialisierbarkeitstheorie:
 - Ablauf ist serialisierbar, wenn es einen äquivalenten seriellen Ablauf seiner Transaktionen gibt
 - Äquivalenz von Abläufen G, H, wenn für jedes Datenobjekt A gilt ($< \hat{=}$ "vor"):

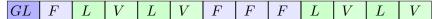
$$r_i[A] <_H w_j[A] \Leftrightarrow r_i[A] <_G w_j[A]$$

 $w_i[A] <_H r_j[A] \Leftrightarrow w_i[A] <_G r_j[A]$
 $w_i[A] <_H w_j[A] \Leftrightarrow w_i[A] <_G w_j[A]$

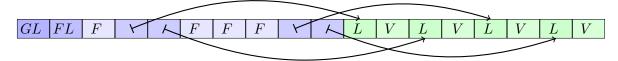
- Abhängigkeitsgraph hat keine Zyklen \Rightarrow Ablauf serialisierbar
- Sperrverfahren mittels Sperrtabelle:
 - Sperrung muss vor Zugriff erfolgen
 - Transaktionen fordern Sperre nicht erneut an
 - Sperren müssen beachtet werden
 - erst am Ende einer Transaktion dürfen Sperren freigegeben werden
 - X-Sperre: exklusiv, für Änderungen notwendig
 - S-Sperre: geteilt, für Lesen notwendig
 - IX-Sperre: exklusiv, zeigt Sperren auf feingranularerer Ebene an
 - IS-Sperre: geteilt, zeigt Sperren auf feingranularerer Ebene an
 - SIX-Sperre: S + IX, wenn alle Tupel gelesen, aber nur einige geändert werden
 - Top-Down-Erwerb, Bottom-Up-Freigabe der Sperren

8 Speicherung

- Speicherung der Tupel in Sätzen:
 - zusammengesetzt aus Feldern mit Namen, Typ und Länge (maximal oder variabel)
 - Metadaten in Systemkatalog gespeichert
 - Satztyp: Menge von Sätzen gleicher Struktur (z.B. Tupel einer Relation)
- verschiedene Speicherungsstrukturen in Sätzen:
 - mit eingebetteten Längenfeldern: Gesamtlänge GL, Inhalt fester Länge F, zu jedem Inhalt variabler Länge V vorher die Länge $L \Rightarrow$ satzinterne Adresse kann nicht direkt aus Katalogdaten berechnet werden



- eingebettete Längenfelder mit Zeigern: Länge des festen Strukturteils FL, Zeiger auf variable Bereiche \Rightarrow satzinterne Adresse kann aus Katalogdaten berechnet werden



- spaltenweises Abspeichern mittels C-Store:
 - vor allem auf das Lesen optimiert
 - Änderungen durch Löschen und Einfügen
 - Projektion:
 - * eine oder mehrere Spalten einer Tabelle (und ggf. anderer, über Fremdschlüssel erreichbare Tabellen) nach einem Attribut sortiert
 - * Speicherschlüssel (Storage Keys, SK) für jedes Tupel, aus Position berechenbar
 - * Verbund-Indizes (Join Indices): Seien T1 und T2 Projektionen der Tabelle T, dann ist ein Join-Index von T1 zu T2 eine Liste von Tupeln aus T2 um den jeweiligen SK aus T1 ergänzt.
 - verschiedene Komprimierungen abhängig von Sortierung und Anzahl der verschiedenen Werte:
 - * sortiert, wenige verschiedene Werte: Tripel (Wert, Position des ersten Auftretens, Anzahl des gleichen Werts) in B-Baum
 - * unsortiert, wenige verschiedene Werte: lauflängenkodierte Bitmaps pro Wert mit B-Baum zum Auffinden der richtigen Bitmap
 - $\ast\,$ sortiert, viele verschiedene Werte: Delta-Kodierung (D
Iffertenz zum Vorgänger) mit B-Baum als Primärorganisation
 - * unsortiert, viele verschiedene Werte: unkomprimiert, bei Zeichenketten Dictionary

9 Anfrageverarbeitung

- Abbildung von mengenorientierten Operatoren auf interne Satzschnittstelle
- Anfrageverarbeitung erstellt einen Anfrageausführungsplan:
 - Analyse: lexikalische und syntaktische Prüfung, semantische Prüfung, Zugriffskontrolle, Integritätskontrolle
 - Optimierung:
 - * Standardisierung und Vereinfachung
 - * algebraische Verbesserung
 - * nicht-algebraische Verbesserung: Berücksichtigung der Kosten der Planoperatoren
 - Code-Generierung
 - Ausführungskontrolle
- logische Operatoren mit Relationen R, S und Prädikat P:
 - Selektion SEL(R, P)
 - Projektion PROJ(R, L) mit $L = (A_1, \ldots, A_k)$
 - Kreuzprodukt CROSS(R, S)
 - Verbund $JOIN(R, S, P(R_{Ai}, S_{Ai}))$
 - Vereinigung UNION(R;S)
 - Schnitt INTERSECT(R,S)

- Ausschluss EXCEPT(R,S)
- analoge Operationen auf Multimengen
- Umbenennung RENAME $(R, R_{\text{neu}}, ((A_i, A_{i,\text{neu}}), \dots))$
- Duplikat-Eliminierung DUP-ELIM(R)
- Aggregation $SUM(R, A_i)$, $AVG(R, A_i)$, $MIN(R, A_i)$, $MAX(R, A_i)$, COUNT(R)
- Gruppierung GROUP(R, L, G) mit $G = ((AGG_1, (A_i), name_1), ...)$
- erweiterte Projektion G-PROJ(R, L) mit $L = (name_1 = expr_1, ...)$
- Sortierung SORT(R, L) mit $L = (A_i, A_j, ...)$
- $\ddot{a}u\beta erer\ Verbund\ OUTER$ -JOIN(R, S, P, c) mit $c \in \{left, right, full\}$
- allgemeine Vorgehensweise bei Restrukturierung:
 - komplexe Verbünde, Selektionen in binäre aufteilen
 - Selektion möglichst "weit unten" ausführen
 - Selektion und Kreuzprodukt zu Verbund gruppieren
 - aufeinander folgende Selektionen der selben Relation zusammenfassen
 - Projektionen möglichst "weit unten" ausführen (aber Duplikat-Eliminierung vermeiden)
- Planoperatoren (können durch *Pipelining* beschleunigt werden):
 - Selektion (Scan):
 - * Kosten: C(R)
 - * Relationen-Scan (Table-Scan): sequentielles Lesen
 - Kosten: B(R)
 - * Index-Scan: Verwendung eines Index

Kosten: $a \cdot \lceil B(R) \cdot \text{Selektivitätsfaktor} \rceil$

- Projektion: in andere Planoperatoren integriert

Kosten: C(R)

- Sortierung
- Join mit Relationen R, S:
 - * Nested-Loop-Join (für Gleichverbund mit Index-Zugriff verbesserbar) Kosten: $C(R) + B(R) \cdot C(S)$
 - * Sorted-Merge-Join (nur für Gleichverbund): sortiere R, S; schritthaltender Scan Kosten: $C(R) + C(S) + 2 \cdot (B(R) + B(T))$
 - * Hash-Join (nur für Gleichverbund): kleinere Relation hashen (bei zu großer Relation mehrere Teile); über größere sequentiellen Scan

Kosten: C(R) + C(S)

- Duplikat-Eliminierung
- Gruppierung
- je nach System/Anwendung Optimierung auf niedrige CPU-/IO-Last
- Statistiken für Wahl des Planoperators sinnvoll (Verteilung der Tupel, Selektivität, ...)

10 Recovery

- *Programmfehler*: Absturz des Datenbank-Anwendungsprogramms ⇒ Daten im Puffer und auf Festplatte in undefiniertem Zustand
- Systemfehler: DBVS oder BS fällt aus, Hardware-Fehler, . . . ⇒ Daten im Puffer verloren, auf Festplatte in undefiniertem Zustand
- $Ger\"{a}tefehler$: Festplattenausfall \Rightarrow Daten auf Festplatte sind verloren
- Transaktionsfehler: z.B. Deadlock, falsche Operationen, Aufruf von rollback bzw. abort
- physische Konsistenz:
 - Korrektheit der Speicherungsstrukturen, Verweise und Adressen
 - alle Indizes sind vollständig und stimmen mit Primärdaten überein
- logische Konsistenz:
 - Korrektheit der Inhalte
 - Referentielle Integrität, Primärschlüsseleigenschaft und eigene Assertions sind erfüllt
 - erfordert physische Konsistenz
- Nach Fehler soll ein logisch konsistenter Zustand erreicht werden:
 - der Zustand vor Beginn der unvollständigen Änderungen durch Rückgängigmachen dieser (undo)
 - * partial: nach Transaktionsfehler Zurücksetzen der fehlgeschlagenen Transaktion
 - * global: nach Systemfehler mit Verlust des Hauptspeicherinhalts Zurücksetzen aller unvollständigen Transaktion
 - * Logging-Informationen müssen vor dem Einbringen gespeichert werden (write-ahead log, WAL)
 - der Zustand nach Abschluss aller Änderungen durch Vervollständigung bzw. Wiederholung der unvollständigen Änderungen (redo)
 - * partial: nach Systemfehler mit Verlust des Hauptspeicherinhalts Wiederholen aller verlorengegangen Änderungen von abgeschlossenen Transaktionen
 - * global: nach Gerätefehler Einspielen des Backups und Nachvollziehen aller danach erfolgreichen Transaktionen
 - * Logging-Informationen müssen vor dem Melden des erfolgreichen Abschlusses geschrieben werden
- Sicherung und Protokollierung (Logging) immer notwendig
- auch Einbringstrategie von Bedeutung:
 - "Wann darf geänderte Seite auf die Festplatte geschrieben werden?"
 - * Steal: auch schon vor Ende der Transaktion bei Verdrängung aus dem Puffer
 - * NoSteal: erst am Ende der erfolgreichen Transaktion
 - "Wann muss geänderte Seite auf die Festplatte geschrieben werden?"
 - * NoForce: erst bei Verdrängung aus dem Puffer (also auch nach Ende einer Transaktion)
 - * Force: spätestens am Ende der erfolgreichen Transaktion
 - "Wie werden geänderte Seiten auf die Festplatte geschrieben?"
 - * NotAtomic: direktes Einbringen, in-place
 - * Atomic: indirektes Einbringen, "Umschalten" von altem auf neuen Zustand

• Protokollverfahren:

- physisch:
 - * Zustandprotokollierung: before-image für undo, after-image für redo, auf Ebene von Seiten oder Sätzen
 - * Seitenprotokollierung: für jede geänderte Seite before-image und after-image sichern
 - $\ast\ Eintragsprotokollierung:$ nur geänderte Teile einer Seite
- Begrenzung des Recovery-Aufwands durch Sicherungspunkte (checkpoints):
 - transaction-oriented checkpoint: Einbringung mittels Force
 - transaction-consistent checkpoint: Beginn neuer Transaktionen verhindern, auf Abschluss der laufenden warten, dann sichern
 - action-consistent checkpoint: keine Änderungsoperation darf aktiv sein, dann sichern; da aber Transaktionen laufen nur Begrenzung von Redo-Recovery

\bullet Wiederherstellungsprozedur:

- Analyse von letztem Checkpoint bis zum Log-Ende
- erfolgreiche Transaktionen gegebenenfalls wiederholen
- fehlgeschlagene Transaktionen von "neu nach alt" rückgängig machen